

Sala de Estudo Inteligente: Levantamento do Estado da Arte sobre Detecção de Ocupação e Conforto Ambiental

Universidade do Minho

Resumo No contexto dos Campus Inteligentes, as bibliotecas universitárias enfrentam desafios constantes relacionados com picos de procura de espaços. A ausência de informação em tempo real sobre a disponibilidade de lugares resulta em ineficiências e degrada a experiência dos utilizadores. Este artigo apresenta uma revisão sistemática da literatura — baseada na análise de 52 publicações do período 2017–2026 — com foco no desenvolvimento de salas de estudo inteligentes sob o paradigma da Inteligência Ambiente. A investigação abrange duas dimensões complementares: a deteção de ocupação, recorrendo a visão computacional e sensores, e a monitorização do conforto ambiental (temperatura, humidade, qualidade do ar, iluminância e ruído). Os resultados revelam que as variantes do modelo YOLO dominam a deteção visual em tempo real, enquanto abordagens baseadas em sensores físicos oferecem alternativas de menor custo. Com base neste levantamento, propõe-se uma arquitetura distribuída assente em dois nós: um nó de visão dedicado à captura e envio periódico de imagens para processamento e inferência YOLO na *cloud*, e um outro nó dedicado à monitorização contínua de métricas ambientais com sensores de baixo custo. Por fim, são discutidas as implicações sociais e éticas do sistema, com especial foco na privacidade de dados e nas tendências futuras da Inteligência Artificial. Este trabalho estabelece o enquadramento teórico e arquitetónico para a implementação prática de um protótipo no contexto da unidade curricular de Sensorização e Ambiente.

Keywords: Sala de Estudo Inteligente · Detecção de Ocupação · Conforto Ambiental · Internet of Things · Visão Computacional · YOLO · Inteligência Ambiente · ESP32 · Privacidade.

1 Introdução

As bibliotecas das instituições de ensino superior são espaços centrais para o estudo e a concentração. Em períodos de maior afluência, a procura excede a oferta, levando os utilizadores a percorrer vários pisos à procura de um lugar livre. Para dar resposta a este tipo de desajuste entre a oferta e a procura nos campi universitários, várias instituições têm vindo a explorar a utilização de ferramentas inteligentes para monitorizar o uso do espaço em tempo real e ajudar

os alunos a encontrar locais de estudo [12]. Esta situação gera ineficiência no uso do tempo e do próprio espaço: algumas salas podem estar sobrelotadas enquanto outras permanecem subutilizadas, sem que os utilizadores tenham forma de o saber à distância através por exemplo, de sensorização [14].

A sensorização do ambiente, combinada com técnicas de processamento de dados e aprendizagem automática, permite inferir o estado de ocupação de um espaço e disponibilizar essa informação em tempo real. Surge assim o conceito de sala de estudo inteligente: um espaço instrumentado com sensores físicos que permitem estimar quantas pessoas se encontram na sala e expor essa informação, para posterior exploração, através de uma aplicação móvel ou *web* [13]. A sala inteligente pode ainda integrar outras dimensões, como o conforto ambiental (temperatura, ruído, CO₂) e a disponibilização de perfis detalhados de cada espaço, sempre que compatível com a privacidade e a ética.

Este conceito enquadra-se no paradigma da Inteligência Ambiente (*Ambient Intelligence* — AmI), conceptualizado pelo grupo ISTAG da Comissão Europeia em 2001, que se refere a ambientes digitais sensíveis e responsivos à presença humana, baseados em três pilares: computação ubíqua, comunicação ubíqua e interfaces inteligentes [27]. A visão seminal de Weiser [28] sobre computação “invisível” no quotidiano materializa-se hoje em sistemas IoT que integram sensores, atuadores e modelos de aprendizagem automática em espaços físicos.

O artigo está organizado da seguinte forma. A Secção 2 descreve a metodologia de investigação. A Secção 3 revê o estado da arte em deteção de ocupação e conforto ambiental. A Secção 4 apresenta a arquitetura proposta para o sistema. A Secção 5 descreve cenários de implementação. A Secção 6 analisa benefícios e riscos da utilização dos dados. A Secção 7 discute as dimensões societais. A Secção 8 conclui o trabalho.

2 Metodologia de Investigação

Para garantir o rigor científico deste levantamento, adotou-se uma metodologia de revisão sistemática inspirada no PRISMA (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*). A pesquisa foi conduzida de 16 de fevereiro a 2 de março de 2026 nas bases de dados IEEE Xplore, ACM Digital Library, Springer, Elsevier (ScienceDirect), MDPI, Semantic Scholar e Google Scholar, utilizando combinações dos termos: “seat occupancy detection”, “smart library”, “indoor occupancy”, “YOLO occupancy”, “IoT classroom”, “environmental comfort classroom” e “smart study room”.

2.1 Critérios de Inclusão e Exclusão

Os artigos foram selecionados com base nos seguintes critérios de inclusão: (1) foco em ambientes educativos, bibliotecas ou espaços interiores comparáveis; (2) abordagens de deteção de ocupação ou monitorização de conforto ambiental; (3) publicação entre 2017 e 2026; (4) validação técnica com métricas quantitativas. Foram excluídos estudos focados exclusivamente em ambientes industriais, transportes ou que não apresentassem resultados experimentais.

2.2 Processo de Seleção

A pesquisa nas bases de dados referidas, combinando os termos descritos, retornou um volume considerável de publicações. Após remoção de duplicados, procedeu-se a uma triagem em duas fases: (1) leitura de título e resumo, excluindo estudos focados em contextos não comparáveis ou sem validação experimental; e (2) leitura integral dos restantes artigos, excluindo os que apresentavam redundância temática ou contributo técnico insuficiente para os objetivos deste levantamento. No total, foram retidas e analisadas 52 publicações que constituem a base bibliográfica deste trabalho, com uma distribuição temporal concentrada nos anos 2022–2025, refletindo a rápida evolução das variantes do modelo YOLO e das soluções IoT de baixo custo para monitorização ambiental.

2.3 Limitações da Revisão

Este levantamento apresenta algumas limitações que devem ser consideradas na interpretação dos resultados. Em primeiro lugar, a pesquisa foi conduzida exclusivamente em língua inglesa, o que pode ter excluído contributos relevantes publicados noutros idiomas. Em segundo lugar, o horizonte temporal de 2017 a 2026, embora abranja a evolução mais significativa das tecnologias analisadas, exclui trabalhos seminais anteriores que poderão ter influenciado a área. Em terceiro lugar, a exclusão de literatura cinzenta (e.g., dissertações não publicadas) e de estudos sem validação experimental quantitativa pode introduzir um viés de publicação favorável a resultados positivos. Por último, a seleção foi conduzida por um único grupo, sem recurso a avaliadores independentes, o que limita a replicabilidade do processo de triagem.

3 Estado da Arte

3.1 Detecção de Ocupação com Câmaras e Visão Computacional

A deteção de ocupação baseada em visão computacional constitui o núcleo técnico mais ativo neste domínio. Os modelos da família YOLO (*You Only Look Once*) e o Faster R-CNN são as arquiteturas dominantes.

Deteção ao Nível do Lugar Individual. Yang *et al.* [1] propõem um modelo de dois canais: Faster R-CNN para deteção de pessoas e um classificador treinado por *transfer learning* para identificação de objetos pessoais (*seat hogging*), distinguindo assim a presença humana da reserva indevida de lugares. Xiao *et al.* [8] introduzem melhorias à arquitetura Faster R-CNN através de técnicas de *skip pooling* e fusão de informação contextual. Güler e Musa [7] utilizam YOLOv8 para mesas de restauração, aplicável a salas de estudo.

Comparação de Arquiteturas. Um estudo de 2024 [3] concluiu que YOLOv8x obteve a melhor precisão (desvio de 6,72% do *ground truth*). Outros estudos compararam YOLOv7 [4], DFV-YOLOv5 [2] e modelos modificados [6] que reduzem a complexidade em 8,6%. De forma a otimizar o compromisso entre a velocidade de inferência e a precisão em tempo real, a literatura mais recente evidencia a transição contínua para iterações mais avançadas da arquitetura, explorando desde o YOLOv5 até configurações baseadas no YOLOv9 e YOLOv10 para ambientes complexos, consolidando o domínio desta família de algoritmos na detecção visual.

Rastreamento Temporal. A utilização isolada de modelos YOLO para contagem de ocupantes pode introduzir instabilidade significativa entre *frames* consecutivas, uma vez que o modelo atribui identificadores distintos à mesma pessoa em cada *frame*. A integração de algoritmos de rastreamento como o DeepSORT [48] resolve este problema ao combinar a predição de movimento via Filtro de Kalman com uma métrica de associação baseada em características de aparência profunda, mantendo a identidade dos ocupantes mesmo após oclusões temporárias. Importa, contudo, notar que a eficácia do Filtro de Kalman depende da frequência de amostragem: com intervalos de 30 segundos, como os propostos na Secção 4, o DeepSORT funciona predominantemente como re-identificação visual e não como rastreador contínuo de trajetórias. Um intervalo mais curto (e.g., 5–10 s) melhoraria a estabilidade, embora à custa de maior consumo energético e tráfego de rede — compromisso a avaliar na fase de prototipagem.

A literatura recente propõe alternativas como ByteTrack, BoT-SORT e StrongSORT, que melhoram a associação em cenários de elevada oclusão. Não obstante, o DeepSORT permanece a solução mais amplamente validada e com integração comprovada com as várias versões do YOLO [48], razão pela qual é adotado neste trabalho.

Câmaras Térmicas vs. RGB. Zhang *et al.* [5] demonstram que, embora as câmaras convencionais ofereçam uma precisão superior 99,1%, as câmaras térmicas surgem como uma alternativa robusta para preservar a privacidade, alcançando uma precisão de 88%. Esta tecnologia revela-se particularmente vantajosa para espaços de estudo, pois mantém a eficácia da monitorização independentemente das condições de iluminação e elimina a resistência dos utilizadores quanto à captação de imagens identificáveis.

Síntese e Lacunas. A análise desta subsecção revela que a família YOLO domina a detecção de ocupação em tempo real, com o YOLOv8 a representar o melhor compromisso atual entre precisão e maturidade do ecossistema. As principais lacunas identificadas incluem: (i) a escassez de estudos que avaliem a detecção coordenada em múltiplas salas com uma arquitetura unificada; (ii) a ausência de validações longitudinais em contexto real durante períodos prolongados; e (iii) a limitada exploração do combate automatizado ao *seat hogging*. Estas lacunas motivam diretamente as escolhas arquitetónicas descritas na Secção 4.

3.2 Monitorização de Conforto Ambiental

Temperatura e Humidade. No que concerne ao conforto térmico, a norma ASHRAE 55 estabelece uma gama de temperatura operativa que, para ambientes de atividade sedentária, se situa tipicamente entre os 20,0 °C e 26,0 °C [52]. Por outro lado, o CIBSE Guide A [51] é frequentemente utilizado para definir os ganhos de calor metabólico e os requisitos de design ambiental em edifícios educativos de elevada ocupação. Mohamed *et al.* [30] descrevem um sistema de automação de sala de aula baseado em Raspberry Pi e sensor DHT11. Fadhel e Aldarabie [31] propõem um sistema integrado de monitorização térmica e acústica em salas de aula. O sensor DHT22 constitui uma solução amplamente adotada na literatura para a medição simultânea de temperatura e humidade relativa em ambientes educativos, oferecendo uma precisão de $\pm 0,5$ °C e ± 2 –5% na humidade relativa. Rahmadani *et al.* [32] validaram o seu desempenho num sistema IoT dedicado à avaliação do conforto térmico, demonstrando elevada exatidão na recolha de dados em contexto real. Paralelamente, Novaliendry *et al.* [41] integraram o mesmo sensor com uma aplicação Android, comprovando que o acesso remoto e contínuo a estes dados permite aos gestores identificar e mitigar rapidamente situações de desconforto térmico.

Qualidade do Ar Interior (IAQ). Kumari *et al.* [33] desenvolveram um sistema IoT de ventilação inteligente baseado em sensores de CO₂, com atuação automática em janelas para manter os níveis abaixo de 1000 ppm. Sistemas de *feedback* visual e acústico sobre os níveis de CO₂ demonstraram melhorar a ventilação das salas de aula [34]. Importa distinguir entre sensores NDIR (*Non-Dispersive Infrared*), como o MH-Z19B ou o SCD30 — este último adotado por Hernandez e Cañas [42] no dispositivo IoT integrado que desenvolveram —, que oferecem medições quantitativas fiáveis de CO₂, e sensores eletroquímicos de gases gerais (e.g., MQ-135), que detetam múltiplos compostos em simultâneo sem capacidade de isolar a concentração de CO₂ [42]. Esta distinção é relevante para a escolha de sensores na arquitetura proposta.

Monitorização de Iluminância. A iluminância é um dos parâmetros ambientais mais determinantes para o desempenho cognitivo em salas de estudo. A norma europeia EN 12464-1 estabelece um mínimo de 500 lux para salas de leitura e estudo [44]. Níveis inadequados — quer por excesso, quer por insuficiência — afetam negativamente a concentração e a produtividade [45,46]. Do ponto de vista do *hardware*, as soluções variam entre sensores digitais de alta resolução e sensores analógicos de baixo custo. Hernandez e Cañas [42] integraram o sensor VEML7700 (resolução de 0,0036 lux, interface I²C) no dispositivo IoT multissensorial que propuseram para *campus* universitários. Em contrapartida, Burunkaya e Duraklar [43] optaram por sensores de luz genéricos priorizando o custo reduzido. O projeto *Smart Lumini* [45] recorreu a uma fotocélula analógica para compensar automaticamente a iluminação artificial em função da luz natural, alcançando uma redução superior a 60% no consumo energético. Kruis-selbrink *et al.* [44] investigaram algoritmos de controlo baseados em luminância

para regulação adaptativa da iluminação artificial, enquanto Chew *et al.* [46] identificaram a integração de sensores IoT de iluminância como fator crítico na transição para edifícios inteligentes, com reduções de 20–40% no consumo energético.

Em síntese, a literatura evidencia um *trade-off* entre custo e precisão: sensores digitais como o VEML7700 permitem leituras quantitativas fiáveis, enquanto fotocélulas analógicas viabilizam apenas classificação qualitativa. Esta lacuna justifica a opção por um LDR na arquitetura proposta, com possibilidade de migração futura.

Monitorização do Conforto Acústico. A OMS recomenda níveis de ruído inferiores a 35 dB(A) para salas de aula durante atividades que exigem concentração, sendo que bibliotecas requerem tipicamente valores da ordem dos 30–40 dB(A) [47]. Marques e Pitarma [47] integraram o DFRobot Gravity Analog Sound Level Meter — calibrado, com gama de 30 a 130 dB(A), erro de $\pm 1,5$ dB e conformidade com a norma IEC 61672 — no sistema *iSoundIoT*, baseado num ESP8266, demonstrando monitorização contínua com acesso remoto via *web*. Hernandez e Cañas [42] optaram pelo microfone MKD-1365 com condicionamento analógico de sinal. Burunkaya e Duraklar [43] instalaram sensores de som genéricos no SCI, obtendo mapas de distribuição sonora que permitiram reduzir a diferença média de níveis entre posições de 21,1 dB para 11,1 dB após *feedback* aos docentes. A integração de mecanismos de *feedback* visual tipo “semáforo” tem demonstrado eficácia na redução sustentada dos níveis de ruído [47]. Nunes e Admiral [50] demonstraram a viabilidade do módulo KY-038 com Arduino para captura de sinais acústicos em protótipos de baixo custo.

A síntese desta subsecção evidencia que as soluções variam entre medidores calibrados de custo médio–elevado e módulos de baixo custo (e.g., KY-038) que apenas fornecem leituras relativas. A lacuna mais relevante é a ausência de procedimentos padronizados de calibração *in situ* para sensores de baixo custo.

Integração Multissensorial para Conforto Ambiental Global. A literatura recente evidencia uma tendência crescente para a integração de múltiplos sensores ambientais numa arquitetura IoT unificada, permitindo a avaliação holística da Qualidade do Ambiente Interior (*Indoor Environmental Quality* — IEQ) [42,43]. Hernandez e Cañas [42] demonstraram que a integração de sensores de temperatura (SHT31), humidade relativa (SHT31), CO₂ (SCD30), iluminância (VEML7700) e ruído (MKD-1365) num único dispositivo IoT permite a sincronização temporal dos dados e a análise de correlações — nomeadamente, verificaram uma correlação de 0,77 entre a concentração de CO₂ e o número de estudantes presentes. Burunkaya e Duraklar [43] monitorizaram e controlaram automaticamente temperatura, humidade, qualidade do ar, iluminância, ruído e poluição particulada com 76 sensores distribuídos por 13 posições. Tagliabue *et al.* [35] demonstraram que a fusão de dados IoT com modelos BIM permite prever a qualidade do ar e otimizar o conforto de forma adaptativa. A aplicação de

técnicas de aprendizagem automática aos dados multissensoriais constitui uma extensão natural desta abordagem [46,43].

3.3 Abordagens IoT, Sensores Alternativos e Integração de Sistemas

As abordagens baseadas exclusivamente em sensores IoT ou de contacto constituem uma alternativa relevante à visão computacional, sobretudo em contextos onde a privacidade ou o custo são fatores determinantes. Sifuentes *et al.* [18] demonstraram a viabilidade de sensores de força resistivos (FSR) instalados sob as cadeiras, alcançando elevada fiabilidade com consumo energético extremamente reduzido. Daniel *et al.* [9] expandiram esta abordagem combinando FSR com etiquetas RFID, alcançando cerca de 99% de precisão. Matuska *et al.* [19] propuseram sensores ultrassónicos para estimar a distribuição de pessoas numa sala de aula.

No domínio das abordagens *device-free*, Zou *et al.* [20] exploraram perturbações nos sinais WiFi para estimar o número de ocupantes. Adeogun *et al.* [21] combinaram dados de múltiplos sensores ambientais com modelos de *deep learning* para inferir a ocupação sem recurso a câmaras. Chaudhari *et al.* [25] apresentaram uma revisão abrangente dos algoritmos e tecnologias de deteção de ocupação baseados em sensores IoT, consolidando o panorama das abordagens não visuais disponíveis. Estas abordagens são particularmente atrativas por preservarem integralmente a privacidade dos utilizadores, embora tipicamente ofereçam menor granularidade espacial.

Para além da sensorização, Xu *et al.* [10] propõem a gestão de lugares via um mini-programa do WeChat, enquanto Álvarez-Merino *et al.* [11] cruzaram dados de ocupação com tecnologia BIM, criando modelos 3D em tempo real. Akhtar e Khatoon [16] validaram a eficácia de sistemas de deteção de ocupação baseados em *edge computing* e *deep learning*, utilizando técnicas de recorte de imagem para otimizar o processamento. O estudo demonstra que o pré-processamento na periferia da rede não só minimiza o tráfego de dados, como também reforça a privacidade ao evitar a transmissão de imagens brutas para a nuvem.

3.4 Visão Comparativa e Síntese Tecnológica

A Tabela 1 apresenta uma comparação das tecnologias de deteção de ocupação abordadas na literatura.

4 Arquitetura

A Figura 1 (Anexo A) apresenta uma visão geral da arquitetura distribuída proposta, com os seus três níveis: sensorização, processamento e apresentação.

Tabela 1. Comparação das tecnologias de detecção de ocupação.

Tecnologia	Precisão	Custo	Privacidade	Granularidade
Câmara RGB	94–99% [3,1]	Médio	Baixa*	Lugar
Câmara Térmica	85–88% [5]	Alto	Alta	Zona
FSR	~99% [9,18]	Baixo/lug.	Alta	Lugar
RFID	~99% [9]	Médio	Média	Lugar
PIR	85–95% [25]	Baixo	Alta	Zona
WiFi	80–95% [20]	Baixo**	Média	Sala
Ultrassónico	90–95% [19]	Baixo	Alta	Lugar
LoRa	91–95% [21]	Baixo	Alta	Sala

*Mitigável com *edge computing* [16]. **Reutiliza infraestrutura existente.

4.1 Camada de Sensorização

A camada de sensorização constitui a base da arquitetura proposta, sendo responsável pela aquisição dos dados brutos do ambiente físico. Adotou-se uma arquitetura distribuída com dois nós independentes, cada um baseado num microcontrolador ESP32, separando as funções de captura visual e monitorização ambiental.

A escolha do ESP32 como plataforma de *hardware* fundamenta-se numa análise comparativa: face ao Arduino Uno, o ESP32 integra nativamente Wi-Fi e Bluetooth, dispensando módulos externos; face ao Raspberry Pi, apresenta menor consumo energético e custo, sendo mais adequado para nós de sensorização dedicados; face a microcontroladores STM32, beneficia de um ecossistema mais acessível para prototipagem e de compatibilidade direta com o módulo ESP32-CAM [49].

Esta separação em dois nós permite que cada um seja otimizado para a sua função específica, evitando os conflitos de recursos que surgiriam ao concentrar todas as funções num único dispositivo. A viabilidade desta abordagem foi recentemente validada por Chang *et al.* [49], que implementaram uma arquitetura de *edge computing* com ESP32-CAM e modelos YOLO comunicando via protocolo MQTT, demonstrando uma redução significativa na latência e no tráfego de rede.

Nó de Visão. O nó de visão é baseado no módulo ESP32-CAM (AI-Thinker), que integra o microcontrolador ESP32-S com uma câmara OV2640 de 2 MP. Este módulo é dedicado exclusivamente à captura e transmissão de imagens: a cada 30 segundos, captura uma *frame* da sala e transmite-a via Wi-Fi para uma plataforma em nuvem. A escolha de um intervalo de 30 segundos justifica-se pela dinâmica lenta da ocupação em salas de estudo; ao contrário de ambientes de restauração ou transportes, os ocupantes permanecem tipicamente durante períodos longos, conforme corroborado pelo estudo de Valks *et al.* [12] sobre a utilização de espaços em *smart campuses*. A ESP32-CAM é instalada no teto da sala, com uma orientação que maximiza a cobertura das mesas e minimiza zonas mortas.

A resolução de 2 MP constitui uma limitação reconhecida, adequada para salas de pequena dimensão (até ~ 20 lugares) mas potencialmente insuficiente para espaços maiores. A arquitetura é, contudo, agnóstica quanto ao dispositivo de captura: em iterações futuras, a ESP32-CAM pode ser substituída por uma câmara USB externa de maior resolução (e.g., 5–16 MP), ou por uma plataforma de *edge computing* como o NVIDIA Jetson Nano, que permitiria executar a inferência localmente, eliminando a transmissão de imagens para a *cloud* [15,49].

Nó Ambiental. O nó ambiental é baseado num ESP32 DevKit V1, que dispõe de um número significativamente maior de portas GPIO e canais ADC livres em comparação com a ESP32-CAM. Este módulo gere a rede de sensores ambientais de baixo custo, cujas características técnicas foram detalhadas na Secção 3.2:

- **DHT11:** sensor digital de temperatura ($\pm 2^\circ\text{C}$) e humidade relativa ($\pm 5\%$), suficiente para monitorização indicativa de conforto térmico [30].
- **MQ-135:** sensor analógico de gases gerais (SnO_2), que fornece uma leitura agregada de múltiplos compostos sem isolar o CO_2 . Requer ambientação a temperaturas ambientes e calibração empírica, mas oferece avaliação qualitativa da qualidade do ar a custo muito reduzido [33,42].
- **LDR:** sensor analógico de luminosidade que permite classificar a iluminação por limiares calibrados empiricamente [45].
- **KY-038:** módulo de som com saídas analógica e digital, adequado para protótipos de monitorização acústica de baixo custo [50].

A seleção destes sensores privilegiou o custo reduzido e a facilidade de prototipagem, admitindo-se a migração para alternativas de maior precisão em iterações futuras.

A frequência de amostragem é de uma leitura a cada 30 segundos. O ESP32 DevKit transmite os dados via Wi-Fi para a mesma plataforma em nuvem utilizada pelo nó de visão, onde são correlacionados temporalmente com as imagens [42]. Opcionalmente, um indicador luminoso LED RGB controlado pelo nó ambiental pode fornecer *feedback* visual local sobre o nível de conforto global da sala, codificando uma avaliação composta que considera o ruído, a temperatura e a qualidade do ar — por exemplo, adotando a cor correspondente ao parâmetro em pior estado ou a uma média ponderada dos indicadores [43,47].

A Tabela 2 resume os sensores propostos para cada nó da camada de sensorização.

4.2 Camada de Processamento e Inferência

A camada de processamento recebe os dados dos dois nós de sensorização através da plataforma em nuvem e executa a inferência num PC dedicado. As imagens enviadas pelo nó de visão são armazenadas temporariamente na *cloud* e descarregadas automaticamente. De seguida, é executado o modelo YOLOv8 para deteção de objetos e o DeepSORT para rastreamento temporal entre *frames* consecutivas, garantindo a estabilidade das contagens [48].

Tabela 2. Sensores propostos para a camada de sensorização da sala de estudo inteligente.

Parâmetro	Sensor	Interface	Gama
Ocupação	OV2640	Wi-Fi	2 MP / 30 s
Temperatura	DHT11	Digital	0–50 °C
Humidade	DHT11	Digital	20–80%
Qualidade do ar	MQ-135	Analógica	Índice relativo*
Iluminância	LDR	Analógica	Qualitativa
Nível sonoro	KY-038	Analógica e Digital	Relativa**

*Sensor de gases gerais (SnO₂); não isola CO₂ — fornece uma leitura agregada proporcional à presença de múltiplos compostos.

**Intensidade sonora relativa; não calibrado em dB(A).

A escolha do YOLOv8, em detrimento das versões mais recentes referidas no estado da arte, fundamenta-se em três fatores: (i) a maturidade do ecossistema — o YOLOv8 dispõe de documentação extensa, facilitando a prototipagem rápida; (ii) a validação empírica — a literatura de 2024 confirma que o YOLOv8x obteve a melhor precisão entre os modelos avaliados em cenários de ocupação densa [3]; e (iii) a compatibilidade comprovada com a ESP32-CAM via MQTT, conforme demonstrado por Chang *et al.* [49]. As versões v9 e v10, embora promissoras, apresentam ainda um ecossistema menos consolidado e menor volume de validação em ambientes interiores comparáveis ao do presente trabalho.

Um desafio prático relevante reside na obtenção de dados anotados para o *fine-tuning* do YOLOv8. Os *datasets* públicos (e.g., COCO, CrowdHuman) podem não representar adequadamente a perspectiva aérea de uma câmara no teto, e a criação de um *dataset* dedicado levanta questões de privacidade (consentimento dos ocupantes) e de custo de anotação manual. Estratégias de mitigação incluem aumento de dados, *transfer learning* a partir de modelos pré-treinados e geração de dados sintéticos [24].

Os dados provenientes do nó ambiental são igualmente recebidos pela plataforma em nuvem e armazenados numa base de dados temporal, onde são correlacionados temporalmente com os resultados da deteção visual. Uma API REST exporta os resultados processados para a camada de apresentação.

No que respeita à plataforma em nuvem, o sistema requer uma solução que cumpra os seguintes requisitos: (i) armazenamento temporário de imagens com eliminação automática após processamento; (ii) base de dados em tempo real para armazenamento de séries temporais de dados ambientais; (iii) mecanismos de autenticação e controlo de acesso; e (iv) compatibilidade com o protocolo MQTT ou HTTP para receção dos dados dos nós ESP32. Plataformas como o Firebase satisfazem estes requisitos, embora outras alternativas sejam igualmente viáveis.

4.3 Camada de Apresentação

A camada de apresentação disponibiliza a informação aos utilizadores finais através de um painel *web* (*dashboard*), uma aplicação móvel e sinalização LED local indicando a disponibilidade de lugares em tempo real, o ruído e outras informações sobre a sala de estudo.

5 Cenários de Implementação

Com base na arquitetura proposta na Secção 4, descrevem-se cenários concretos de implementação.

5.1 Detecção por Visão Computacional

A arquitetura de deteção visual pode ser adaptada a diferentes configurações espaciais. Numa sala de pequena dimensão (até 20 lugares), uma única ESP32-CAM é suficiente para cobrir a totalidade das mesas; em salas maiores ou com *layouts* irregulares, múltiplas câmaras exigem um mecanismo de fusão de deteções para evitar contagens duplicadas. O sistema classifica cada lugar como *livre*, *ocupado* ou *reservado por objetos* (*seat hogging*) [1].

A classificação de *seat hogging* introduz uma ambiguidade temporal: objetos sem ocupante podem indicar tanto uma ausência temporária (e.g., ida à casa de banho) como uma reserva indevida prolongada. O sistema deverá incorporar um limiar temporal configurável — por exemplo, menos de 10 minutos como ausência temporária e mais de 30 minutos como *seat hogging* — implementável via *timestamps* da última deteção de presença, sem rastreamento individual.

Em condições de iluminação variável, a degradação do desempenho pode ser mitigada por técnicas de aumento de dados ou pela utilização de câmaras térmicas [5]. A transmissão de imagens para a *cloud* requer encriptação em trânsito (TLS) e em repouso, eliminação automática após a inferência e restrição de acesso por autenticação.

5.2 Integração Móvel e Informação das Salas

A informação de ocupação e de conforto ambiental é exposta através de uma API REST e consumida por uma aplicação móvel e por um painel *web* responsivo. A interface apresenta uma planta simplificada com código de cores — verde para mesas livres, amarelo para parcialmente ocupadas, laranja para mesas com apenas um lugar e vermelho para ocupadas — permitindo ao estudante consultar a disponibilidade antes de se deslocar à biblioteca [12,13]. A aplicação pode incorporar notificações *push* para alertar quando um lugar se torna disponível numa sala favorita. Adicionalmente, a plataforma disponibiliza um perfil detalhado e em tempo real de cada sala, integrando a taxa de ocupação, a distribuição espacial dos lugares e os indicadores de conforto ambiental (temperatura, qualidade do ar, iluminação e ruído), permitindo aos utilizadores optar, por exemplo, pela

sala mais silenciosa. Os parâmetros ambientais são comparados com limiares de referência — 20–26 °C para temperatura [41], ruído “baixo”, “moderado” ou “elevado” [47], qualidade do ar “aceitável” vs. “necessita ventilação” — e, dada a natureza indicativa dos sensores de baixo custo, o sistema disponibiliza alertas qualitativos em vez de valores metrológicos absolutos, notificando os gestores do espaço quando um parâmetro excede o limiar definido. Esta abordagem puramente informativa promove uma distribuição orgânica e eficiente da procura pelas várias salas do *campus* [12].

6 Benefícios e Riscos

6.1 Benefícios

A implementação de uma sala de estudo inteligente proporciona benefícios em três dimensões fundamentais.

A primeira diz respeito à eficiência na gestão do espaço. A disponibilização de dados de ocupação em tempo real permite aos estudantes identificar rapidamente salas com lugares disponíveis, reduzindo o tempo despendido na procura e promovendo uma distribuição mais equilibrada da utilização dos espaços académicos [12].

A segunda dimensão refere-se à eficiência energética. A correlação entre os dados de ocupação e os parâmetros ambientais viabiliza a adaptação dinâmica dos sistemas de climatização, ventilação e iluminação à utilização efetiva do espaço. Choi *et al.* [17] reportaram uma redução de cerca de 10% no consumo energético anual de AVAC e iluminação em escritórios que integram a contagem de ocupantes baseada em visão computacional. Complementarmente, Mutis *et al.* [29] demonstraram que o controlo da ventilação baseado na ocupação real conduz a uma redução do consumo energético sem comprometer a qualidade do ar interior. No que concerne à iluminação, a regulação automática pode representar uma redução adicional de 20–40% no consumo energético associado [46].

A terceira dimensão prende-se com a melhoria do conforto e do desempenho académico. Ambientes com temperatura controlada [43], iluminação adequada [46] e níveis de ruído reduzidos [47] estão associados a uma maior capacidade de concentração e satisfação dos utilizadores.

6.2 Riscos

Os riscos inerentes ao sistema devem ser cuidadosamente identificados e mitigados.

O risco mais significativo reside na privacidade. Embora as instituições de ensino superior disponham tipicamente de sistemas de videovigilância nos espaços comuns, a arquitetura proposta introduz um risco acrescido ao transmitir imagens para a *cloud*, ampliando a superfície de exposição face a um circuito fechado convencional. A mitigação exige encriptação em trânsito e em repouso, eliminação imediata das imagens após a inferência e controlo rigoroso de acesso.

Ahmad *et al.* [26] alertam ainda para o risco de rastreamento inadvertido de padrões comportamentais a partir de metadados de ocupação. Estes aspetos são discutidos em maior detalhe na Secção 7.

Um segundo risco concerne a cibersegurança. A transmissão de dados via Wi-Fi e o seu armazenamento temporário na *cloud* expõem o sistema a vetores de ataque: intercetção em trânsito (mitigada por TLS), acesso não autorizado à plataforma, exploração de vulnerabilidades na API REST e comprometimento de nós ESP32 na rede local [26,39]. Num cenário de *data breach*, a eliminação imediata das imagens limita a exposição, embora os metadados retidos possam ainda constituir informação sensível sujeita às obrigações de notificação do RGPD.

Um terceiro risco refere-se aos erros de precisão e fiabilidade. Variações de iluminação, oclusões parciais e alterações no *layout* podem degradar o desempenho dos modelos de deteção, gerando falsos positivos [3]. Nos sensores ambientais, o MQ-135 constitui o caso mais crítico, dado que a incapacidade de isolar gases individuais pode originar leituras enganosas, exigindo calibração periódica e interpretação cautelosa [42].

Por fim, os custos de manutenção — energia, substituição de componentes e atualização de *software* — e a escalabilidade para múltiplas salas devem ser cuidadosamente planeados [12].

7 Dimensões Societais

7.1 Ludificação

A ludificação tem sido explorada em bibliotecas académicas como estratégia para aumentar o envolvimento dos estudantes [36]. Não obstante, a implementação de mecânicas de ludificação convencionais — baseadas em pontos, *rankings* e recompensas individuais — pressupõe a existência de contas e perfis de utilizador que permitam rastrear ações individuais, o que conflitua diretamente com o princípio de minimização de dados consagrado no RGPD e amplia a superfície de risco em matéria de privacidade [38,39]. Adicionalmente, Reed e Miller [37] evidenciaram que a aceitação da ludificação varia entre grupos de utilizadores, sugerindo que a eficácia da abordagem depende fortemente do *design* e do público-alvo.

Face a estas limitações, propõe-se uma abordagem de ludificação coletiva e anónima, compatível com a arquitetura *privacy-by-design*. O mecanismo utiliza o indicador LED ou *display* à entrada da sala para exibir um ícone expressivo (e.g., *smiley*) cujo estado reflete o nível médio de ruído recente: indicador positivo (rosto sorridente verde) quando o ruído se mantém abaixo de 30–40 dB(A) [47], progredindo para expressões neutras (amarelo) e negativas (vermelho) com o aumento do ruído. Este princípio de *feedback* visual coletivo foi validado por Marques e Pitarma [47] e por Burunkaya e Duraklar [43].

A vantagem reside no facto de constituir uma recompensa de grupo que incentiva a autorregulação comportamental sem identificação individual ou sistema de contas. A “recompensa” é intrínseca e partilhada, criando uma norma social implícita de respeito pelo ambiente de estudo, preservando integralmente a privacidade e utilizando apenas os dados agregados já recolhidos pelo nó ambiental.

7.2 Privacidade

A privacidade dos utilizadores constitui a dimensão societal mais sensível. A utilização de câmaras e de sensores capazes de detetar a presença humana suscita preocupações legítimas relativas à vigilância, ao rastreamento comportamental e à potencial identificação dos indivíduos. O RGPD estabelece princípios fundamentais que devem orientar a conceção destes sistemas, nomeadamente a minimização de dados, a limitação da finalidade e a *privacy by design* [38,39].

No caso concreto da arquitetura proposta, em que a ESP32-CAM transmite imagens para a *cloud*, os riscos de privacidade são acrescidos face a soluções baseadas em *edge computing*. A mitigação exige: (i) encriptação das imagens em trânsito (TLS/HTTPS); (ii) encriptação em repouso; (iii) eliminação automática das imagens após a inferência, retendo apenas metadados anonimizados; (iv) restrição do acesso mediante autenticação robusta; e (v) redução opcional da resolução ao mínimo necessário para a deteção, limitando a possibilidade de identificação facial [26,39]. Ahmad *et al.* [26] propõem a utilização de dados ambientais agregados como *proxy* complementar para a estimativa de ocupação. A transparência para com os utilizadores — através de sinalização visível sobre a presença, natureza e finalidade de cada sensor — é igualmente fundamental [39].

7.3 Ética

A análise ética do sistema é enquadrada pelo *framework* PAPA (*Privacy, Accuracy, Property, Accessibility*), proposto por Mason [40].

No que respeita à privacidade, o sistema deve assegurar que os dados recolhidos não possibilitem a identificação de utilizadores individuais, cumprindo o princípio de minimização de dados do RGPD. A dimensão da precisão impõe que a informação seja fiável, dado que decisões baseadas em dados incorretos degradam a confiança no sistema.

A dimensão da propriedade levanta questões sobre a titularidade dos dados: é essencial que permaneçam sob controlo institucional e não sejam partilhados com terceiros para fins comerciais [39]. A acessibilidade exige que o sistema seja inclusivo, garantindo que todos os estudantes — incluindo aqueles com necessidades especiais ou sem *smartphone* — possam beneficiar da informação, por exemplo através de sinalização física.

Um risco ético particularmente relevante é o *chilling effect*: embora os utilizadores estejam habituados à videovigilância genérica, a monitorização granular ao nível do lugar individual pode intensificar a perceção de vigilância e inibir a utilização espontânea do espaço [26,39]. A mitigação passa pela transparência, pela limitação da granularidade dos dados e pelo envolvimento dos estudantes na governação do sistema.

7.4 Tendências Futuras

O campo das salas inteligentes encontra-se em rápida evolução, sendo possível identificar quatro tendências com particular relevância.

A *Edge AI* permite reduzir a latência, diminuir a dependência de conectividade e reforçar a privacidade [15]. A evolução de *hardware* especializado (e.g., NVIDIA Jetson) está a tornar viável a execução de modelos YOLO em dispositivos de baixo consumo. Embora a arquitetura proposta opte pelo processamento centralizado, a migração para *edge computing* constituiria uma evolução natural, eliminando a transmissão de imagens para a *cloud* [49].

Os *Digital Twins* integram em tempo real os dados de todos os sensores numa réplica virtual do espaço. Álvarez-Merino *et al.* [11] demonstraram a viabilidade de integrar dados de ocupação em modelos BIM para uma gestão mais eficaz.

O *Federated Learning* permite o treino colaborativo de modelos entre múltiplas salas ou instituições, sem que os dados brutos abandonem cada local de origem [24].

A fusão multimodal de sensores combina dados de visão, sensores ambientais, redes WiFi e sinais acústicos, superando as limitações individuais de cada tecnologia [22,23].

8 Conclusão

Este trabalho contribuiu com uma revisão sistemática e a proposta de uma arquitetura distribuída de baixo custo para salas de estudo universitárias. A análise de 52 publicações do período 2017–2026 identificou o domínio de modelos YOLO para deteção em tempo real e a maturidade de sensores IoT de baixo custo para monitorização de conforto ambiental. A arquitetura distribuída proposta, com dois nós ESP32 — um nó de visão dedicado à captura e envio de imagens para a *cloud* a cada 30 segundos, e um nó ambiental com sensores DHT11, MQ-135, LDR e KY-038 — constitui uma solução de custo reduzido, robusta e de fácil implementação. A integração de DeepSORT para rastreamento temporal complementa o YOLOv8, garantindo contagens de ocupação estáveis.

A análise identificou limitações relevantes nos sensores de baixo custo, em particular a incapacidade do MQ-135 de isolar a concentração de CO₂, que deve ser compensada pela interpretação qualitativa dos dados e pela eventual migração para sensores NDIR em iterações futuras do protótipo. Os cenários de implementação demonstram a viabilidade de um sistema que combina deteção de ocupação, monitorização ambiental e a disponibilização de informação detalhada das salas em tempo real. A análise de benefícios e riscos evidenciou que as vantagens em termos de eficiência energética, gestão de espaços e conforto académico justificam o investimento, desde que sejam implementadas medidas rigorosas de mitigação dos riscos de privacidade e cibersegurança — particularmente relevantes na arquitetura proposta, em que as imagens transitam pela *cloud*.

As lacunas identificadas na literatura — nomeadamente a deteção coordenada em múltiplas salas, o combate automatizado ao *seat hogging* e a validação longitudinal em contexto real — orientarão o desenvolvimento do protótipo prático na segunda fase deste trabalho.

A Diagrama de Arquitetura




Figura 1. Arquitetura distribuída da sala de estudo inteligente: camadas de sensorização, processamento e apresentação.

Referências

1. Yang, G., Chang, X., Wang, Z., Yang, M.: A serial dual-channel library occupancy detection system based on Faster RCNN. arXiv preprint arXiv:2306.16080 (2023). <https://arxiv.org/abs/2306.16080>

2. Wang, C., Zhang, Y., Zhou, Y., Sun, S., Zhang, H., Wang, Y.: Automatic detection of indoor occupancy based on improved YOLOv5 model. *Neural Comput. Appl.* **35**(31), 2575–2599 (2023). <https://doi.org/10.1007/s00521-022-07730-3>
3. Zhang, W., Calautit, J., Tien, P.W., Wu, Y., Wei, S.: Deep learning models for vision-based occupancy detection in high occupancy buildings. *J. Build. Eng.* **84**, 108544 (2024). <https://doi.org/10.1016/j.jobbe.2024.111355>
4. Zhou, S., Zhang, W., Tien, P.W., Calautit, J.: Evaluating single-shot and two-stage vision-based detection of occupancy activity in energy-efficient buildings. *Energy Build.* **345**, 116017 (2025). <https://doi.org/10.1016/j.enbuild.2025.116017>
5. Zhang, W., Li, J., Tien, P.W., Calautit, J.K.: Vision-based occupancy detection in indoor environments: A comparison of standard RGB and thermal cameras. *J. Build. Eng.* **114**, 114215 (2025). <https://doi.org/10.1016/j.jobbe.2025.114215>
6. Zhang, H., Liu, L., Bi, J., Liu, H., Wen, Z., Bi, L., Yao, G.: Modified lightweight YOLOv8 model for fast and precise indoor occupancy detection. *Appl. Sci.* **14**(1), 335 (2024). <https://doi.org/10.3390/app16010335>
7. Güler, A.K., Musa, A.: Real-time table occupancy detection in restaurants using object detection and computer vision techniques. *J. Artif. Intell. Data Sci.* **5**(1), 12–27 (2025). <https://izlik.org/JA79MT36EX>
8. Xiao, Y., Wang, X., Zhang, P., Meng, F., Shao, F.: Object detection based on Faster R-CNN algorithm with skip pooling and fusion of contextual information. *Sensors* **20**(19), 5490 (2020). <http://dx.doi.org/10.3390/s20195490>
9. Daniel, O.C., Ramsurrun, V., Seeam, A.K.: Smart library seat, occupant and occupancy information system, using pressure and RFID sensors. In: 2019 Conference on Next Generation Computing Applications (NextComp). pp. 1–5. IEEE (2019). <https://doi.org/10.1109/NEXTCOMP.2019.8883610>
10. Xu, X., Guo, Z.-M., Zhu, Y.-R.: Design of seat management system in smart library. In: IEEE ICOT Conference, pp. 1–5. IEEE (2022). <https://doi.org/10.1109/ICOT56925.2022.10008128>
11. García-Granja, M.J., Blázquez-Parra, E.B., Cimadomo, G., Guzmán-Navarro, F.: Development of an innovative seat reservation system for university buildings based on BIM technology. *Buildings* **12**(11), 1786 (2022). <https://doi.org/10.3390/buildings12111786>
12. Valks, B., Arkesteijn, M., den Heijer, A.: Smart campus tools 2.0: exploring the use of real-time space use measurement at universities and organizations. *Facilities* **37**(13/14), 961–980 (2019). <http://dx.doi.org/10.1108/F-11-2018-0136>
13. Valks, B., Arkesteijn, M.H., Koutamanis, A., den Heijer, A.C.: Towards a smart campus: supporting campus decisions with Internet of Things applications. *Build. Res. Inf.* **49**(1), 1–20 (2021). <https://doi.org/10.1080/09613218.2020.1784702>
14. Tunahan, G.I., Altamirano, H.: Seating behaviour of students before and after the COVID-19 pandemic: Findings from occupancy monitoring with PIR sensors at the UCL Bartlett Library. *Int. J. Environ. Res. Public Health* **19**(20), 13255 (2022). <https://doi.org/10.3390/ijerph192013255>
15. Monti, L., Tse, R., Tang, S.K., Mirri, S., Delnevo, G., Maniezzo, V., Salomoni, P.: Edge-based transfer learning for classroom occupancy detection in a smart campus context. *Sensors* **22**(10), 3692 (2022). <https://doi.org/10.3390/s22103692>
16. Akhtar, T., Mahmood, A., Khatoon, S.: Occupancy Detection for HVAC Systems Using IoT Edge Computing and Vision-Based Image Processing. In: 2024 IEEE/ACM 17th International Conference on Utility and Cloud Computing (UCC). IEEE (2024). <https://doi.org/10.1109/UCC63386.2024.00074>

17. Choi, H., Um, C.Y., Kang, K., Kim, H., Kim, T.: Application of vision-based occupancy counting method using deep learning and performance analysis. *Energy Build.* **252**, 111389 (2021). <https://doi.org/10.1016/j.enbuild.2021.111389>
18. Sifuentes, E., Gonzalez-Landaeta, R., Cota-Ruiz, J., Reverter, F.: Seat occupancy detection based on a low-power microcontroller and a single FSR. *Sensors* **19**(3), 699 (2019). <https://doi.org/10.3390/s19030699>
19. Matuska, S., Machaj, J., Hudec, R., Kamencay, P.: An improved IoT-based system for detecting the number of people and their distribution in a classroom. *Sensors* **22**(20), 7912 (2022). <https://doi.org/10.3390/s22207912>
20. Zou, H., Zhou, Y., Yang, J., Spanos, C.J.: Device-free occupancy detection and crowd counting in smart buildings with WiFi-enabled IoT. *Energy Build.* **174**, 309–322 (2018). <https://doi.org/10.1016/j.enbuild.2018.06.040>
21. Adeogun, R.O., Rodriguez, I., Razzaghpour, M., Berardinelli, G., Christensen, P.H., Mogensen, P.: Indoor occupancy detection and estimation using machine learning and measurements from an IoT LoRa-based monitoring system. In: 2019 Global IoT Summit (GIOTS). pp. 1–6. IEEE (2019). <https://doi.org/10.1109/GIOTS.2019.8766374>
22. Chen, Z., Jiang, C., Xie, L.: Building occupancy estimation and detection: A review. *Energy Build.* **169**, 260–270 (2018). <https://doi.org/10.1016/j.enbuild.2018.03.084>
23. Rueda, L., Agbossou, K., Cardenas, A., Henao, N., Kelouwani, S.: A comprehensive review of approaches to building occupancy detection. *Build. Environ.* **180**, 106966 (2020). <https://doi.org/10.1016/j.buildenv.2020.106966>
24. Sayed, A.N., Himeur, Y., Bensaali, F.: Deep and transfer learning for building occupancy detection: A review and comparative analysis. *Eng. Appl. Artif. Intell.* **115**, 105254 (2022). <https://doi.org/10.1016/j.engappai.2022.105254>
25. Chaudhari, P., Xiao, Y., Cheng, M.M.C., Li, T.: Fundamentals, algorithms, and technologies of occupancy detection for smart buildings using IoT sensors. *Sensors* **24**(7), 2123 (2024). <https://doi.org/10.3390/s24072123>
26. Ahmad, J., Larijani, H., Emmanuel, R., Mannion, M., Javed, A.: Occupancy detection in non-residential buildings - a survey and novel privacy preserved occupancy monitoring solution. *Appl. Comput. Inform.* **17**(2), 279–295 (2021). <https://doi.org/10.1016/j.aci.2018.12.001>
27. Cook, D.J., Augusto, J.C., Jakkula, V.R.: Ambient intelligence: Technologies, applications, and opportunities. *Pervasive Mob. Comput.* **5**(4), 277–298 (2009). <https://doi.org/10.1016/j.pmcj.2009.04.001>
28. Weiser, M.: The computer for the 21st century. *Sci. Am.* **265**(3), 94–104 (1991). <https://doi.org/10.1038/scientificamerican0991-94>
29. Mutis, I., Ambekar, A., Joshi, V.: Real-time space occupancy sensing and human motion analysis using deep learning for indoor air quality control. *Autom. Constr.* **116**, 103237 (2020). <https://doi.org/10.1016/j.autcon.2020.103237>
30. Mohamed, A.A., Ahmed, M.M., Ali, A.A., Afwah, A.A.: Smart classroom automation system. *SSRG Int. J. Electr. Electron. Eng.* **11**(11), 131–138 (2024). <https://doi.org/10.14445/23488379/IJEEE-V11I11P114>
31. Fadhel, M.I., Aldarabie, A.: Smart thermal environmental and noise monitoring to enhance classroom comfort. *WSEAS Trans. Environ. Dev.* **20**, 213–221 (2024). <https://doi.org/10.37394/232015.2024.20.84>
32. Arifin, F., Shiddiq, A.M., Agnia, N.S., Nofal, M.: Design and development of IoT-based temperature and humidity monitoring system for thermal comfort evaluation in classrooms. *J. Phys.: Conf. Ser.* **2673**, 012024 (2023). <https://doi.org/10.1088/1742-6596/2673/1/012011>

33. Kumari, S., Sharma, S., Sharma, N.: IoT-based smart ventilation control in classroom. *SSRN Electron. J.* 4938634 (2024). <https://dx.doi.org/10.2139/ssrn.5752522>
34. Pierucci, A., Messeri, A., Orlandini, S., Albertoni, T.: Improving classroom air quality and ventilation with IoT-driven acoustic and visual CO₂ feedback system. *Sci. Total Environ.* **962**, 178317 (2025). <https://doi.org/10.1016/j.scitotenv.2025.179543>
35. Tagliabue, L.C., Cecconi, F.R., Rinaldi, S., Ciribini, A.L.C.: Data driven indoor air quality prediction in educational facilities based on IoT network. *Energy Build.* **236**, 110782 (2021). <https://doi.org/10.1016/j.enbuild.2021.110782>
36. Walsh, A.: The potential for using gamification in academic libraries in order to increase student engagement and achievement. *Nord. J. Inf. Lit. High. Educ.* **6**(1), 39–51 (2014). <https://doi.org/10.15845/noril.v6i1.214>
37. Reed, K., Miller, A.: Applying gamification to the library orientation: A study of interactive user experience and engagement preferences. *Inf. Technol. Libr.* **39**(3), 1–19 (2020). <https://doi.org/10.6017/ital.v39i3.12209>
38. O'Connor, Y., Rowan, W., Lynch, L., Heavin, C.: Balancing privacy rights and surveillance analytics: A decision process guide. *J. Bus. Anal.* **4**(2), 155–170 (2021). <https://doi.org/10.1080/2573234X.2021.1920856>
39. Wang, X., Wu, Y.C., Zhou, M., Fu, H.: Beyond surveillance: privacy, ethics, and regulations in face recognition technology. *Front. Big Data* **7**, 1337465 (2024). <https://doi.org/10.3389/fdata.2024.1337465>
40. Mason, R.O.: Four ethical issues of the information age: Privacy, accuracy, property, and accessibility. *MIS Q.* **10**(1), 5–12 (1986). <https://doi.org/10.2307/248873>
41. Novaliendry, D., Ifelga, I., Ikhwan, I., Junaidi, J., Adri, M.: Smart classroom IoT-based Android for temperature and humidity monitoring to enhance student learning comfort. *Int. J. Interact. Mob. Technol.* **19**(24), 4–18 (2025). <https://doi.org/10.3991/ijim.v19i24.58885>
42. Hernandez, W., Cañas, N.: Sensing classroom temperature, relative humidity, illuminance, CO₂, and noise: An integral solution based on an IoT device for dense deployments. *Sensors* **24**(16), 5129 (2024). <https://doi.org/10.3390/s24165129>
43. Burunkaya, M., Duraklar, K.: Design and implementation of an IoT-based smart classroom incubator. *Appl. Sci.* **12**(4), 2233 (2022). <https://doi.org/10.3390/app12042233>
44. Kruisselbrink, T.W., Dangol, R., van Loenen, E.J.: A comparative study on luminance-based lighting control algorithms. *Energy Build.* **228**, 110429 (2020). <https://doi.org/10.1016/j.enbuild.2020.110429>
45. González-Amarillo, C.A., Cárdenas-García, C.L., Caicedo-Muñoz, J.A., Mendoza-Moreno, M.A.: Smart Lumini: A smart lighting system for academic environments using IoT-based open-source hardware. *Rev. Fac. Ing.* **29**(54), e11060 (2020). <https://doi.org/10.19053/01211129.v29.n54.2020.11060>
46. Chew, I., Karunatilaka, D., Tan, C.P., Kalavally, V.: Smart lighting: The way forward? Reviewing the past to shape the future. *Energy Build.* **149**, 180–191 (2017). <https://doi.org/10.1016/j.enbuild.2017.04.083>
47. Marques, G., Pitarma, R.: A real-time noise monitoring system based on Internet of Things for enhanced acoustic comfort and occupational health. *IEEE Access* **8**, 139741–139755 (2020). <https://doi.org/10.1109/ACCESS.2020.3012919>
48. Wojke, N., Bewley, A., Paulus, D.: Simple online and realtime tracking with a deep association metric. In: 2017 IEEE International Conference on Image Processing

- (ICIP). pp. 3645–3649. IEEE (2017). <https://doi.org/10.1109/ICIP.2017.8296962>
49. Chang, Y.H., Wu, F.C., Lin, H.W.: Design and implementation of ESP32-based edge computing for object detection. *Sensors* **25**(6), 1656 (2025). <https://doi.org/10.3390/s25061656>
 50. Nunes, J.B., Admiral, T.D.: Use of Arduino and flute in teaching waves in a high school class. *Braz. J. Sci.* **3**(2), 33–44 (2024). <https://doi.org/10.14295/bjs.v3i2.469>
 51. CIBSE: Environmental design: CIBSE Guide A. Chartered Institution of Building Services Engineers, London (2015). <https://www.cibse.org/knowledge-research/knowledge-portal/guide-a-environmental-design-2015>
 52. ASHRAE: ANSI/ASHRAE Standard 55-2023: Thermal Environmental Conditions for Human Occupancy. ASHRAE, Peachtree Corners (2023). <https://www.ashrae.org/technical-resources/bookstore/standard-55-thermal-environmental-conditions-for-human-occupancy>